

附件一：Tox21 分子毒性预测：图神经网络基线实验

一、实验动机及相关工作

分子毒性预测是药物发现早期筛选的核心环节。本研究基于 Tox21 数据集，系统评估了 GCN、GIN、GraphSAGE 等图神经网络在分子毒性预测中的性能。GIN 与 GraphSAGE 在测试集上达到 0.85 AUC，与文献基准 D-MPNN 持平，验证了 GNN 在分子性质预测中的工程可行性。

1.1 为什么选择 Tox21 数据集

Tox21 (Toxicology in the 21st Century) 是美国 NIH、EPA 和 FDA 联合发起的分子毒性预测基准数据集，是分子性质预测领域最权威的 benchmark 之一。选择 Tox21 作为研究起点的原因如下：

- ✧ 标准化 benchmark: Tox21 是 MoleculeNet 核心数据集之一，有明确的 train/val/test 划分和公开的文献基准，便于与已有工作对比。
- ✧ 多任务学习: 包含 12 个毒性预测任务（7 个核受体信号通路、5 个应激反应通路），可评估模型在多任务场景下的泛化能力。
- ✧ 中等规模: 7831 个分子样本，适合在 CPU 环境下进行快速实验迭代，验证算法思路。
- ✧ 临床意义: 毒性预测是药物研发的关键环节，早期筛选可显著降低开发成本和失败风险。

1.2 为什么选择图神经网络

分子天然具有图结构（原子为节点，化学键为边），图神经网络（GNN）能够直接在图结构上进行学习和推理，相比传统方法具有显著优势：

- ✧ 端到端学习: 无需手工设计分子描述符，直接从分子图结构学习表示。
- ✧ 可解释性: 可以通过注意力权重或 GNNExplainer 等方法分析模型关注的子结构。
- ✧ 迁移学习潜力: 学到的分子表示可以迁移到其他性质预测任务。

1.3 分子表示学习

分子表示学习是分子性质预测的核心问题。传统方法依赖手工设计的分子描述符，如 ECFP (Extended Connectivity Fingerprint) [Rogers & Hahn, 2010]。深度学习时代，研究者提出了多种分子表示方法：

- ✧ 序列表示：将 SMILES 字符串视为序列，使用 RNN/LSTM/Transformer 建模。
- ✧ 图表示：直接在分子图上应用 GNN，学习原子级表示并池化为分子表示。
- ✧ 3D 表示：考虑分子的 3D 构象，使用 SE(3)等变网络。

1.4 图神经网络发展

GNN 在分子性质预测中的应用经历了快速发展：

年份	方法	贡献
2017	GCN	谱图卷积的简化版本，高效且可扩展
2017	MPNN	消息传递框架统一多种 GNN
2018	GAT	引入注意力机制，自适应聚合邻居
2019	GIN	证明 GNN 与 WL 测试的关系，最大表达能力
2019	D-MPNN	有向边消息传递，分子专用架构
2020	MolCLR	分子图对比学习预训练
2022	Graphormer	Transformer+图结构编码

1.5 预训练与迁移学习

近年来，预训练-微调范式在分子表示学习领域取得重要进展：

- ✧ MolCLR (2020)：对比学习预训练，在 1000 万分子上学习通用表示
- ✧ Uni-Mol (2022)：3D 分子预训练，结合构象信息

✧ GEM (2022): 几何增强分子表示学习

✧ MolecularGPT (2024): 大语言模型驱动分子理解

二、实验方法

2.1 数据集

Tox21 数据集包含 7831 个分子，12 个毒性预测任务：

任务类别	具体任务
核受体信号通路（7 个）	NR-AR, NR-AR-LBD, NR-AhR, NR-Aromatase, NR-ER, NR-ER-LBD, NR-PPAR-gamma
应激反应通路（5 个）	SR-ARE, SR-ATAD5, SR-HSE, SR-MMP, SR-p53

数据划分：Train/Val/Test = 6264/783/784 (~80%/10%/10%)

2.2 特征工程

使用 RDKit 计算分子图特征：

- ✧ 原子特征（28 维）：原子类型、度、形式电荷、杂化态、芳香性、氢原子数等
- ✧ 键特征（6 维）：键类型、共轭性、键方向等
- ✧ 池化策略：mean + max 双重池化，捕获全局统计信息

2.3 模型架构

实现并对比以下 GNN 架构：

模型	核心思想	参数量
GCN	谱图卷积，邻居聚合权重固定	72K

GIN	最大表达能力，可区分 WL 测试能区分的图	122K
GraphSAGE	采样聚合框架，可扩展到大图	108K
GIN+ECFP	图表示与分子指纹融合	469K
GIN+JK	Jumping Knowledge，结合多层表示	321K
GIN+AttnPool	注意力加权池化	125K

2.4 训练策略

- 所有模型采用统一的训练设置：
- ✧ 优化器：AdamW (lr=1e-3, weight_decay=1e-5)
 - ✧ 损失函数：BCEWithLogitsLoss（多标签分类）
 - ✧ 学习率调度：ReduceLROnPlateau
 - ✧ 早停策略：patience=20 epochs
 - ✧ 评估指标：ROC-AUC（忽略缺失标签）

三、实验结果

3.1 基线模型对比

模型	Val AUC	Test AUC	参数量	训练时间(s)
GIN	0.8455	0.8500	122K	368
GraphSAGE	0.8412	0.8502	108K	346
GCN	0.8653	0.8282	72K	552

- ✧ GIN 和 GraphSAGE 达到相同 Test AUC (~0.85)，与文献 D-MPNN 基准持平
- ✧ GCN 严重过拟合（Val 0.87 vs Test 0.83），泛化能力最弱




图 1. 基线模型性能对比

3.2 增强策略实验

策略	Test AUC	参数量	结果分析
GIN-base (3L)	0. 8478	122K	基线
GIN+ECFP 融合	0. 8246	469K	高维稀疏特征导致过拟合
GIN+JK-Net	0. 8474	321K	参数翻倍但无提升
GIN+AttnPool	0. 8366	125K	注意力池化未能改善

如图 2 所示，所有增强策略均未突破基线，在有限数据下，可能增加模型复杂度反而有害。这为小样本情况下的图神经网络改进提供了可能性。




图 2. 增强模型性能对比

3.3 预训练特征验证

尝试使用 MolCLR 预训练模型（对比学习，1000 万分子预训练）提取特征，然后训练传统机器学习模型：

方法	Test AUC
MolCLR + Logistic Regression	0.7821
MolCLR + Random Forest (200 trees)	0.7744
MolCLR + Random Forest (100 trees)	0.7658

分析：MolCLR 预训练特征在 Tox21 上表现远不如从零训练（差 7 个点），可能原因：

- ✧ 预训练任务（对比学习结构相似性）与下游任务（毒性预测）目标不匹配
- ✧ Linear Probe 模式下冻结 encoder，无法学习任务特定特征
- ✧ Tox21 数据量太小，预训练特征的泛化优势无法体现

3.4 与文献基准对比

方法	Test AUC	来源
Random Forest + ECFP	~ 0.82	MoleculeNet Benchmark
GIN (文献)	~ 0.83	MoleculeNet Benchmark
D-MPNN	~ 0.85	Yang et al., 2019
Graphormer	~ 0.86	Ying et al., 2022

本次实验并未进行多论实验和验证，仅在有限条件下复现相关论文中的模型，并在复现过程中了解相关研究进展，为本人后续开展研究提供思路。

硬件环境：

✧ MacBook Pro, CPU-only 训练

软件环境：

✧ Python 3.12

✧ PyTorch 2.2.2

✧ PyTorch Geometric 2.7.0

✧ RDKit 2025.9.3

✧ NumPy 1.26.4

代码仓库：

Github: <https://github.com/WayneDevMaze/AIDDLearn>